2ème Année Master Architectures et Applications des Systèmes d'Information

Prédiction du vainqueur de la Coupe du Monde de Football 2022



Réalisé par : Responsable :

BOUAFIA Youssef Pr. FRIKH Bouchra

EL HADAD Amina

Année Universitaire: 2023/2024

Extraire et nettoyer des données historiques afin de leur appliquer un modèle statistique.

La coupe du monde de football 2022 a débuté dimanche Sans se concentrer sur le côté sportif (forme et méforme des joueurs et équipes),

Emparons-nous du sujet pour en faire un projet DATA complet en 3 étapes:

- 1) Extraire les données historiques qui vont nous permettre de répondre à l'objectif
- 2) Nettoyer les données récoltées
- 3) Construire plusieurs modèles prédictifs et choisir le meilleur.

Nom	Modifié le	Туре	Taille
donnees	02/01/2023 15:25	Dossier de fichiers	
1.scrapping_tableaux_phase_de_groupe	02/01/2023 15:24	JetBrains DataSpell	11 Ko
2.scrapping_match(Qata2022_worldcup)	02/01/2023 15:18	JetBrains DataSpell	4 Ko
3.cleaning_worldcup_match	02/01/2023 15:24	JetBrains DataSpell	5 Ko
4.cleaning_Qatatr2022_match	02/01/2023 15:25	JetBrains DataSpell	10 Ko
5.predection_Qatar2022	02/01/2023 14:06	JetBrains DataSpell	71 Ko

Figure 1- Dossier qui contient tout le projet

Étape 1 - Récolter des données historiques des précédentes Coupes du Monde de Football

utiliser Python et BeautifulSoup pour extraire les données de toutes les coupes du monde jouées jusqu'à présent (1930-2018) et le tableau de la coupe du monde 2022.

Donc une première étape classique de Web Scraping!

Faire le web scraping des datasets

Figure 2- Scrapping des groupes stage



چامیمة سیدي محمد برج عبد الله †ه ۱۰۰۵مال ۲۱ کی ۱۰۵۸ E°کر E°کر الله ⊕ Université Sidi Mohamed Ben Abdellah

```
In 20 1 cimport pandas as pd
from bs4 import BeautifulSoup
cimport requests

In 27 1 cdef 'get_matches(y):
    site = f'https://en.wikipedia.org/wiki/{y}-FIFA_World_Cup'
    req = requests.get(site)
    content = req.text
    soup = BeautifulSoup(content, 'lxml')
    matches = soup.find_all('div', class_='footballbox')
    home = []
    score = []
    away = []
    for match in matches:
        home.append(match.find('th', class_='fhome').get_text())
        score.append(match.find('th', class_='faway').get_text())

dict_foot= {'home': home, 'score': score, 'away': away}
    football = pd.DataFrame(dict_foot)
    football['year'] = y
    return football
```

Figure 3-Fonction de Scrapping

```
years = [ 1930,1934,1950,1954,1958,1962,1966,1970,1974,1978,1982,1986,1990,1994,1998,2002,2006, 2010, 2014, 2018]

# les anciennes match

worldcup_match = [get_matches(year) for year in years]
worldcup_match = pd.concat(worldcup_match, ignore_index=True)
worldcup_match.to_csv("donnees/worldcup_match.csv", index=False)

#les matches de coupe du monde 2022

Qatar2022 = get_matches(2022)
Qatar2022.to_csv('donnees/Qatar2022_match.csv', index=False)
```

Figure 4-Scapping des anciens matchs et des match du Qatar 2022



چامعة سيدي محمد بي عبد الاه †ه ۱۰۵۸ اخ کاره کاره کاره کاره کاره کاره کاره Université Sidi Mohamed Ben Abdellah

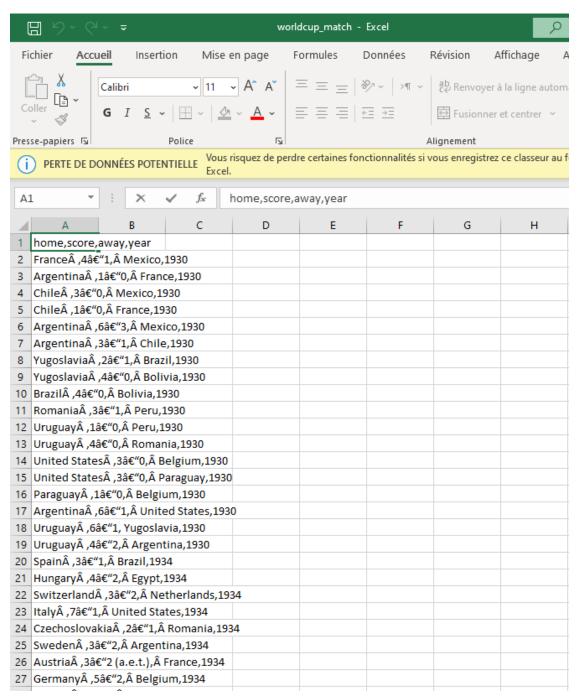


Figure 5- Le fichier CSV qui contient les anciens matchs

المدرسة الوطنية الهاوم التطبيقية † الداد الادعان التادي الادعان الدادة الادعادة الادعادة الادعادة Ecole Nationale des Sciences Appliquées de Fès



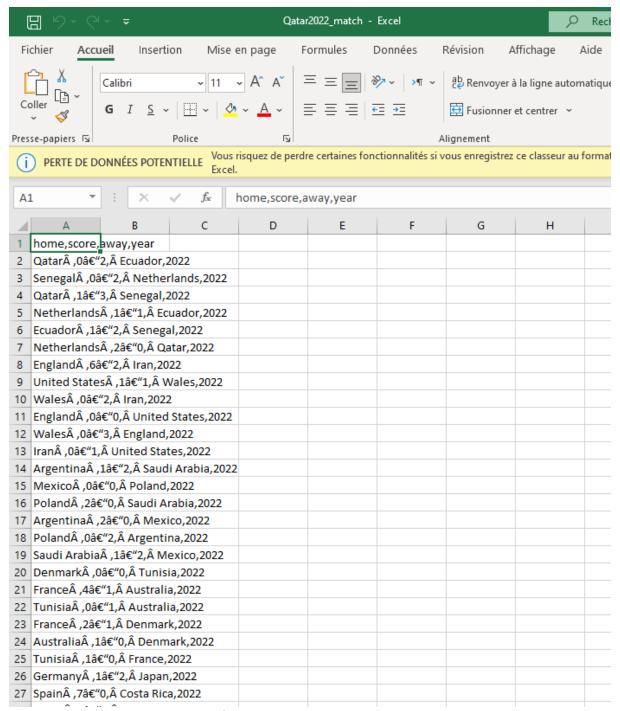


Figure 6- Le fichier CSV qui contient les matchs du Qatar 2022

المدرسة الوطنية للجلوم التطبيقية | ۱۱=۱۱ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ + ۱۱۵ | Ecole Nationale des Sciences Appliquées de Fès



چاه ی ه سیدي ه دهند بی کبند الاه †ه ۱۰۵۸ اخ با ۱۰۵۸ اخ ک کارد الاه بی کبند الاه Université Sidi Mohamed Ben Abdellah

Étape 2 - Nettoyer les données des matchs et de leurs résultats

Les Data Scientists passent 60 % de leur temps à nettoyer et organiser les données.

Cela montre l'importance du nettoyage et du traitement des données dans un projet de Data Science.

utiliser les fonctions principales de Pandas pour nettoyer et transformer un ensemble de données qui sera utilisé dans la 3ème partie du projet Data.

→ 2 étapes en 1 : (Data Cleaning + Data Wangling)



چاهیجهٔ سیدي محمد بری بحبد الله †ه ۱۰۵۸ه الک ۱۰۵۸ = ۱۰۵۸ه ک ۱۲۵ م.۵۰۵ الله Université Sidi Mohamed Ben Abdellah

Figure 7- Cleanning des matchs du Qatar 2022



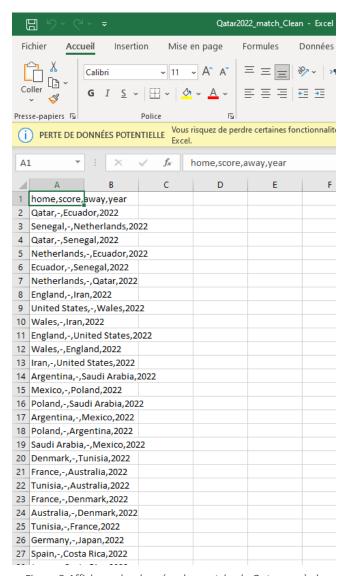


Figure 8-Affichage des données des matchs du Qatar après le nettoyage



Figure 9- Cleaning des anciens matchs



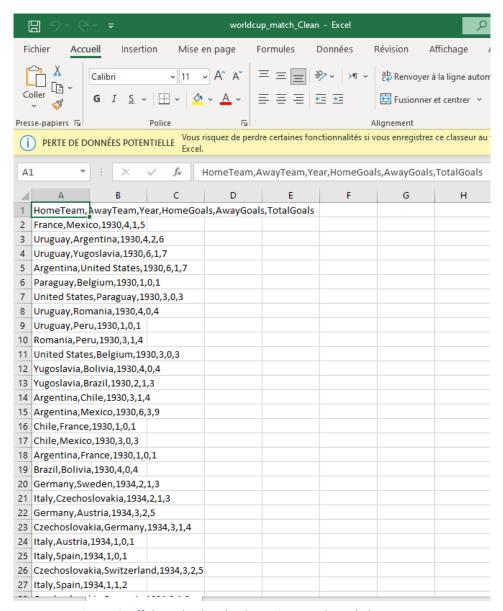


Figure 10- Affichage des données des anciens matchs après le nettoyage

المدرسة الوطنية للخلوم التطبيقية | ۱۱۲۵ | ۱۱۲۵ | ۱۲۵۵ | ۱۲۵۵ | ۱۲۵۵ | ۱۲۵۵ | | Ecole Nationale des Sciences Appliquées de Fès



جامعة سيدي محمد بن عبد الله †ه ۱۹۵۸ الله الک ۱۹۵۸ اله ۱۹۵۸ الله Université Sidi Mohamed Ben Abdellah

Étape 3 - Prédire le résultat de chaque match jusqu'au vainqueur

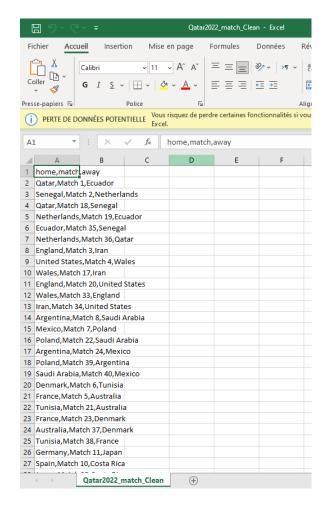
Beaucoup de gens parlent du football comme d'un jeu imprévisible parce qu'un match de football comporte différents facteurs (arbitrage, blessures, cartons rouges, chance...) qui peuvent changer le score final.

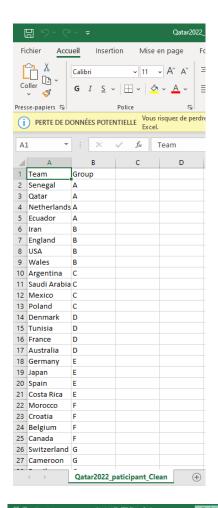
Il est difficile de prédire le score final ou le vainqueur d'un match, mais ce n'est pas le cas lorsqu'il s'agit de prédire le vainqueur d'une compétition.

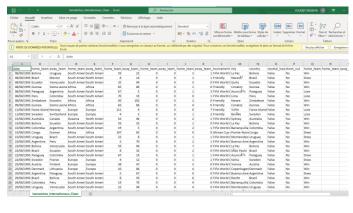


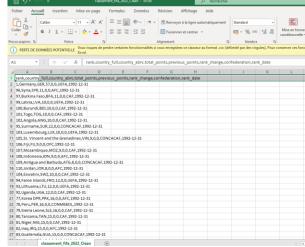
جامعة سيدي محمد بن عبد الله †ه ۱۹۵۸ اک ۸هے کا کاره کا کاله ۱۹۵۸ کاله کاره Université Sidi Mohamed Ben Abdellah

Voilà les 4 fichiers dont on a besoin : les classements fifa, les équipes participants, les matchs internationaux et les matchs du Qatar 2022.









المدرسة الوطنية للخلوم النطبيقية †ا الدال †مادة الحدد الحدد المداري في الخالا الداري الداري الداري المدرسة الوطنية المدرسة ا



چاه ی ه سیدي ه دهند بی کبند الاه †ه ۱۰۵۸ اخ با ۱۰۵۸ اخ ک کارد الاه بی کبند الاه Université Sidi Mohamed Ben Abdellah

```
In 125 1 comport pandas as pd
2 import pickle
3 import numpy as np
4 from sklearn.model_selection import train_test_split
5 from sklearn.svm import SVC
6 of from sklearn.ensemble import RandomForestClassifier

In 126 1 match=pd.read_csv("data 2/Qatar2022_match_Clean.csv")
2 equipe = pd.read_csv("data 2/Qatar2022_paticipant_Clean.csv", sep=";")
3 classement = pd.read_csv("data 2/classement_fifa_2022_Clean.csv")
4 data_match = pd.read_csv("data 2/lesmatches_internationaux_Clean.csv", sep=";")
5 dict_table = pickle.load(open('data 2/dict_table','rb'))
```

Figure 11-Les bibliothèques importées

Figure 12- Données divisées sur un nouveau colonne

Figure 13- Les Accuracy des deux modèles



ېاهېخه سپيدې محمد برو کبد الله ۱۰۵۸۰⊔۶۴ ⊙۶۸۶ ⊑°، ۱۳۵۸ خا ښه نوی Université Sidi Mohamed Ben Abdellah

Figure 14- Les équipes participants

Figure 15- Fonction avec SVC pour la prédiction des points des groupes Stage

```
In 149  1  phase_de_groupes = match[:48].copy()
2   huitieme_de_finale = match[48:56].copy()
3   quarts_de_finale = match[65:60].copy()
4   demi_finale = match[60:62].copy()
5   final = match[62:].copy()
```

Figure 16- Les différentes phases de la compétition



Figure 17- Prédiction des groupes Stage

```
group_winner={}
for group in dict_table:
    group_winner[group] = dict_table[group].loc[0, 'Team'],dict_table[group].loc[1, 'Team']

group_winner

{'Group A': ('Netherlands', 'Senegal'),
    'Group B': ('England', 'Iran'),
    'Group C': ('Argentina', 'Mexico'),
    'Group D': ('France', 'Denmark'),
    'Group E': ('Spain', 'Germany'),
    'Group F': ('Belgium', 'Croatia'),
    'Group G': ('Brazil', 'Switzerland'),
    'Group H': ('Uruguay', 'Portugal')}
```

Figure 18- Affichage des gagnants du groupe Stage



جامعة سيدي محمد بن عبد الله †ه اله اله الح. الح. ك كالم. ك كاله. ك الله. Université Sidi Mohamed Ben Abdellah

Figure 19- Affichage des matchs du Huitième-final

Figure 20- Fonction de prédiction des phases éliminatoires

```
Gdef get_winner(match):
    for index, row in match.iterrows():
        home, away = row['home'], row['away']
        winn = predict_victory(home, away)
        if winn=='home':
            winner = home
        else:
            winner = away
        match.loc[index, 'winner'] = winner
        return match
```

Figure 21- Fonction qui implémente les gagnants des matchs à l'aide de la fonction de prediction predict_victory



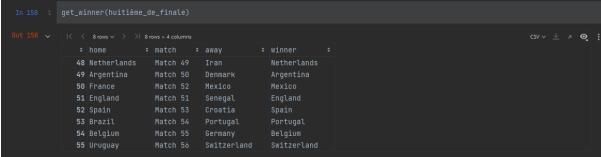


Figure 22- Affichage des gangnats du huitième-final

Figure 23-Afficher les équipes des matchs de la phase suivante

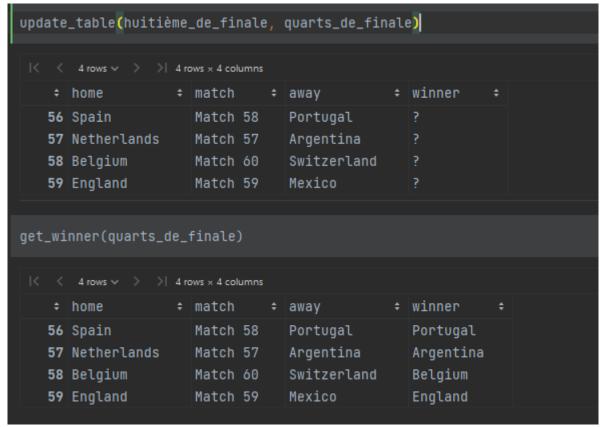


Figure 24- Affichage des gagnants du quart-final



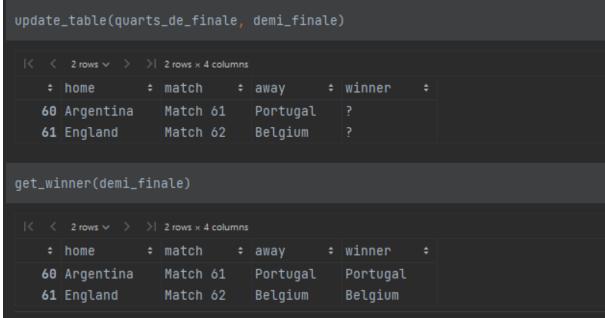


Figure 25- Affichage des gagnants du demi-final



Figure 26- Affichage du vainqueur de la coupe du monde 2022